


Capítulo 6

Chapter Precap

- Efectos condicionales y efectos marginales (promedio) "principales".
- Cruzamiento y anidamiento, y la importancia del cruzamiento para la estimación de interacciones.
- Modelos con múltiples parámetros dependientes de grupos ('efectos aleatorios') y la interpretación de estos como interacciones.
- Introducir la distribución normal multivariante, además de los conceptos de multidimensionalidad y correlación.
- El uso de distribuciones normales multivariadas en la estimación de efectos aleatorios.
- Por último, una introducción y explicación de la comparación y selección de modelos.



Listener Variation in the Age Effect

$$\text{height} \sim A + (1|L) + (1|S)$$



Listener Variation in the Age Effect

$$\text{height} \sim A + (1|L) + (1|S)$$



Data

```
# load packages and data
library (bmmb)
library (brms)
data (exp_data)

# exclude actual men and apparent men
notmen = exp_data[exp_data$C_v!='m' & exp_data$C!='m',]
```

The relevant variables in our data frame are:


- **L**: An integer from 1 to 15 indicating which *listener* responded to the trial.
- **height**: A floating-point number representing the *height* (in centimeters) reported for the speaker on each trial.
- **S**: An integer from 1 to 139 indicating which *speaker* produced the trial stimulus.
- **A**: The *apparent age* of the speaker indicated by the listener, **a** (adult) or **c** (child).

Research Questions

- (1) ¿Qué tan altas suenan las hablantes percibidos como mujeres adultas?
- (2) ¿Qué tan altos suenan los hablantes percibidos como niños?
- (3) ¿Cuál es la diferencia de altura aparente asociada a la percepción de la adultez?

Main and Interaction Effects




- Los efectos principales son promedios, efectos marginales (e.g., $P(A)$).
- Las interacciones reflejan el efecto de algún predictor, condicionado por el valor de otro (e.g., $P(A|L)$).
- En muchos casos los efectos marginales no son iguales a los efectos condicionados a otras variables (e.g., $P(A) \neq P(A|L)$).



Main and Interaction Effects

- Los efectos principales se denotan un nombre o una letra, por ejemplo, A, S, L.
- Las interacciones se denotan con un ':', que puede leerse como 'dado'. Por lo tanto, los siguientes términos pueden leerse así:
 - 'L': el efecto del oyente.
 - 'A': el efecto de la edad aparente.
 - 'A:L': el efecto de la edad aparente dado el oyente.
 - 'L:A': el efecto de los oyentes dada la edad aparente.




Interaction Effects



Interaction Effects

¿Dónde se puede ver?

- 'L': el efecto del oyente.
- 'A': el efecto de la edad aparente.
- 'A:L': el efecto de la edad aparente dado el nivel del oyente.
- 'L:A': el efecto de los oyentes dada la edad aparente.



Description of our Model

Último capítulo $\longrightarrow$ `height ~ 1 + A + (1 | L) + (1 | S)`

Supongamos que solo
tiene efectos fijos $\longrightarrow$ `height ~ 1 + A + L + S`

A:L le dice a nuestro modelo
que estime los efectos de la
edad en función del oyente. $\longrightarrow$ `height ~ 1 + A + L + A:L + S`

$A * L = A + L + A:L$ $\longrightarrow$ `height ~ 1 + A * L + S`

Description of our Model

Interacciones de efectos 'fijos'.

`height ~ 1 + A * L + S`

`height ~ 1 + A + L + A:L + S`

interacciones de efectos 'aleatorios'.




`height ~ 1 + A + (1 + A | L) + (1 | S)`

Parámetros equivalentes

`height ~ 1 + A + L + A:L + S`
`height ~ 1 + A + (1 + A | L) + (1 | S)`

Crossing and Nesting

- Cruzado: Todos los niveles de un factor aparecen en todos los niveles del otro.
- Anidado: Algunos niveles de un factor solo aparecen en algunos niveles del otro.
- Solo se pueden estimar las interacciones si se cruzan factores



Crossing and Nesting: Example

- Si cada oyente tiene una lengua materna.....
- Se puede estimar el efecto de la lengua materna en los juicios de altura.

```
height ~ NatLang + (1|L)
```

- No se puede estimar la interacción de idioma materno y oyente.

```
height ~ NatLang + (NatLang|L)  
height ~ NatLang + L + NatLang:L
```

Comparing Models

`height ~ 1 + A + (1 + A|L) + (1|S)`

$$\text{height}_{[i]} \sim t(v, \mu_{[i]}, \sigma)$$

$$\mu_{[i]} = \text{Intercept} + A + L_{[L[i]]} + A:L_{[L[i]]} + S_{[S[i]]}$$

Priors :

$$L_{[.]} \sim N(0, \sigma_L)$$

$$A:L_{[.]} \sim N(0, \sigma_{A:L})$$

$$S_{[.]} \sim N(0, \sigma_S)$$

$$\text{Intercept} \sim t(3, 156, 12)$$

$$A \sim t(3, 0, 12)$$

$$\sigma_L, \sigma_S, \sigma_{A:L} \sim t(3, 0, 12)$$

$$v \sim \text{gamma}(2, 0.1)$$

$$\sigma \sim t(3, 0, 12)$$

`height ~ 1 + A + L + A:L + S`

$$\text{height}_{[i]} \sim t(v, \mu_{[i]}, \sigma)$$

$$\mu_{[i]} = \text{Intercept} + A + L_{[L[i]]} + A:L_{[L[i]]} + S_{[S[i]]}$$

Priors :

$$L_{[.]} \sim N(0, 12)$$

$$A:L_{[.]} \sim N(0, 12)$$


$$S_{[.]} \sim N(0, 12)$$

$$\text{Intercept} \sim t(3, 156, 12)$$

$$A \sim t(3, 0, 12)$$

$$v \sim \text{gamma}(2, 0.1)$$

$$\sigma \sim t(3, 0, 12)$$



Correlation

$$\hat{r} = \frac{\hat{\sigma}_{xy}}{\hat{\sigma}_x \hat{\sigma}_y}$$

Coeficiente de
correlación de Pearson

$$\hat{r} = \frac{\Sigma (x_{[i]} - \bar{x})(y_{[i]} - \bar{y})}{(n - 1) \cdot \hat{\sigma}_x \hat{\sigma}_y}$$

Covarianza

$$\hat{\sigma}_{xy} = \frac{\Sigma (x_{[i]} - \bar{x})(y_{[i]} - \bar{y})}{(n - 1)}$$

Correlation




```
x1 = c(-1, -1, 1, 1)
y1 = c(-2, -2, 2, 2)
cor(x1, y1)
## [1] 1
```

```
x1 = c(-1, -1, 1, 1)
y1 = c(2, 2, -2, -2)
cor(x1, y1)
## [1] -1
```



```
x1 = c(-1, -1, 1, 1)
y1 = c(-2, 2, -2, 2)
cor(x1, y1)
## [1] 0
```

```
x1 = c(-1, -1, 1, 1)
y1 = c(-2, -2, -2, 2)
cor(x1, y1)
## [1] 0.5774
```


Correlated Random Effects



Correlated Random Effects



Multivariate Normal Distribution



$$\Sigma = \begin{bmatrix} \sigma_L^2 & \sigma_{L,A:L} \\ \sigma_{A:L,L} & \sigma_{A:L}^2 \end{bmatrix}$$

Priors for the Covariance Matrix

- 1 Specify priors for the standard deviation of each dimension. $\sigma_L, \sigma_S, \sigma_{A:L} \sim t(3, 0, 12)$
- 2 Specify a prior for the correlation matrix for the multivariate normal used for the random parameters. $R \sim \text{LKJCorr}(\eta)$

brms muestrea matrices de correlación


$$R = \begin{bmatrix} 1 & r_{L,A:L} \\ r_{A:L,L} & 1 \end{bmatrix}$$

Y 'construye' la matriz de covarianza por ti

$$\Sigma = \begin{bmatrix} \sigma_L^2 & \sigma_{L,A:L} \\ \sigma_{A:L,L} & \sigma_{A:L}^2 \end{bmatrix} = \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix} \cdot R \cdot \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix}$$

Lewandowski-Kurowicka-Joe (LKJ) Distribution

$$R \sim \text{LKJCorr}(\eta)$$



Model Description

We are modeling apparent height as coming from a t distribution with unknown nu (ν), mean (μ), and scale (σ) parameters. The expected value for any given trial (μ) is modeled as the sum of an intercept, an effect for apparent age (A), a listener effect (L), a listener dependent effect for apparent age ($A:L$), and a speaker effect (S). The speaker effects were drawn from a univariate normal distribution with a standard deviation (σ_S) estimated from the data. The two listener effects were drawn from a bivariate normal distribution with standard deviations ($\sigma_L, \sigma_{A:L}$) and a correlation matrix (R) that was estimated from the data. The remainder of the 'fixed' effects and the bivariate correlation were given prior distributions appropriate for their expected range of values.

$$\text{height}_{[i]} \sim t(\nu, \mu_{[i]}, \sigma)$$

$$\mu_{[i]} = \text{Intercept} + A + L_{[L[i]]} + A:L_{[L[i]]} + S_{[S[i]]}$$

Priors:

$$S_{[\cdot]} \sim N(0, \sigma_S)$$

$$\begin{bmatrix} L_{[\cdot]} \\ A:L_{[\cdot]} \end{bmatrix} \sim \text{MVNormal}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \Sigma\right)$$

$$\begin{aligned} \text{Intercept} &\sim t(3, 156, 12) \\ A &\sim t(3, 0, 12) \\ \sigma, \sigma_L, \sigma_{A:L}, \sigma_S &\sim t(3, 0, 12) \\ \nu &\sim \text{gamma}(2, 0.1) \\ R &\sim \text{LKJCorr}(2) \end{aligned}$$

$$\Sigma = \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix} \cdot R \cdot \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix}$$

Comparing Models

$$\text{height}_{[i]} \sim t(\nu, \mu_{[i]}, \sigma)$$

$$\mu_{[i]} = \text{Intercept} + A + L_{[L[i]]} + A:L_{[L[i]]} + S[S[i]]$$

Priors :

$$L_{[\cdot]} \sim N(0, \sigma_L)$$

$$A:L_{[\cdot]} \sim N(0, \sigma_{A:L})$$

$$S_{[\cdot]} \sim N(0, \sigma_S)$$

$$\text{Intercept} \sim t(3, 156, 12)$$

$$A \sim t(3, 0, 12)$$

$$\sigma_L, \sigma_S, \sigma_{A:L} \sim t(3, 0, 12)$$

$$\nu \sim \text{gamma}(2, 0.1)$$

$$\sigma \sim t(3, 0, 12)$$

$$\text{height}_{[i]} \sim t(\nu, \mu_{[i]}, \sigma)$$

$$\mu_{[i]} = \text{Intercept} + A + L_{[L[i]]} + A:L_{[L[i]]} + S[S[i]]$$

Priors :

$$S_{[\cdot]} \sim N(0, \sigma_S)$$

$$\begin{bmatrix} L_{[\cdot]} \\ A:L_{[\cdot]} \end{bmatrix} \sim \text{MVNormal}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \Sigma\right)$$

$$\text{Intercept} \sim t(3, 156, 12)$$

$$A \sim t(3, 0, 12)$$

$$\sigma, \sigma_L, \sigma_{A:L}, \sigma_S \sim t(3, 0, 12)$$

$$\nu \sim \text{gamma}(2, 0.1)$$

$$\rightarrow R \sim \text{LKJCorr}(2)$$

$$\rightarrow \Sigma = \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix} \cdot R \cdot \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix}$$

Fitting the Model

```
# Fit the model yourself
priors = c(brms::set_prior("student_t(3,156, 12)", class = "Intercept"),
  brms::set_prior("student_t(3,0, 12)", class = "b"),
  brms::set_prior("student_t(3,0, 12)", class = "sd"),
  brms::set_prior("lkj_corr_cholesky (2)", class = "cor"),
  brms::set_prior("gamma(2, 0.1)", class = "nu"),
  brms::set_prior("student_t(3,0, 12)", class = "sigma"))

model_re_t =
  brms::brm (height ~ A + (A|L) + (1|S), data = notmen, chains = 4,
    cores = 4, warmup = 1000, iter = 5000, thin = 4,
    prior = priors, family = "student")
```

$$\text{height}_{[i]} \sim t(\nu, \mu_{[i]}, \sigma)$$

$$\mu_{[i]} = \text{Intercept} + A + L_{[L[i]]} + A:L_{[L[i]]} + S_{[S[i]]}$$

Priors:

$$S_{[\cdot]} \sim N(0, \sigma_S)$$

$$\begin{bmatrix} L_{[\cdot]} \\ A:L_{[\cdot]} \end{bmatrix} \sim \text{MVNormal}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \Sigma\right)$$

$$\text{Intercept} \sim t(3, 156, 12)$$

$$A \sim t(3, 0, 12)$$

$$\sigma, \sigma_L, \sigma_{A:L}, \sigma_S \sim t(3, 0, 12)$$

$$\nu \sim \text{gamma}(2, 0.1)$$

$$\rightarrow R \sim \text{LKJCorr}(2)$$

$$\Sigma = \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix} \cdot R \cdot \begin{bmatrix} \sigma_L & 0 \\ 0 & \sigma_{A:L} \end{bmatrix}$$

More stuff in the L Random Effect

- Ahora tenemos más de un efecto aleatorio por oyente.
- También obtenemos una estimación de la correlación entre los predictores.

```
## Group-Level Effects:  
## ~L (Number of levels: 15)  
##  
##           Estimate Est.Error 1-95% CI u-95% CI  
## sd(Intercept)      4.34      0.84    3.05    6.29  
## sd(A1)             4.26      0.85    2.96    6.25  
## cor(Intercept,A1) -0.80      0.12   -0.95   -0.51
```

Helper Functions

```
bmmb::get_sds (model_re_t)
```

```
##           Estimate Est.Error   Q2.5  Q97.5  group
## Int.L      4.338      0.8356  3.050  6.289      L
## A1         4.258      0.8463  2.964  6.248      L
## Int.S      3.057      0.3594  2.398  3.808      S
## sigma      5.354      0.2057  4.958  5.770  sigma
```

```
# specify that we want the correlations for L
```


```
bmmb::getcorrs (model_re_t, factor="L")
```

```
##           Estimate Est.Error   Q2.5   Q97.5
## A1, Int.  -0.8018      0.1151 -0.9491 -0.5087
```

Consequences of Random Slopes

$$\text{height} \sim A + (A|L) + (1|S)$$

$$\text{height} \sim A + (1|L) + (1|S)$$



Model Comparison

- Es concebible que pueda ajustar varios modelos diferentes a cualquier conjunto de datos.
- ¿Cómo saber cuál debes usar?
- Un problema particular es que los modelos más complicados siempre se ajustan a los datos al menos tan bien como los modelos menos complicados.

Bias Variance Tradeoff

- Si vendes ropa, puedes vender ropa que le quede muy bien a todo el mundo, pero luego necesitas muchos modelos diferentes.
 - Excelente ajuste, pero muchos modelos diferentes = bajo sesgo, alta varianza.
- También puede vender una pequeña cantidad de modelos que se adapten bastante bien a todos, pero a casi ninguno perfectamente.
 - Peor ajuste, pero pocos modelos diferentes = alto sesgo, baja varianza.

In and out of sample data

- En datos de muestra: Los datos que tiene, e. g., y
- Datos fuera de la muestra: Los datos que no tienes, pero que son igual que los datos que tienes, por ejemplo, $\tilde{y}$.
- En general, solo te importan los $\tilde{y}$.
- Sobreajuste: Cuando el modelo es tan bueno prediciendo y que es malo prediciendo $\tilde{y}$.

In and out of sample prediction

- Densidad predictiva logarítmica (puntual), lpd: la densidad logarítmica de los datos dada la modelo.

$$\widehat{\text{lpd}} = \sum_{i=1}^N \log\left(p(y_{[i]} | \theta)\right)$$

- Densidad predictiva logarítmica esperada (puntual), elpd: el valor esperado de la densidad logarítmica de los datos que no tiene, dado su modelo.

$$\text{elpd} = \sum_{i=1}^N \mathbb{E}\left(\log\left(p(\tilde{y}_{[i]} | \theta)\right)\right)$$

Simulating Prediction

```
n = 50          # how many observations
iter = 1000     # how many simulations

# these will hold the model log likelihoods for each iteration
lpd_hat = matrix(0, iter, 3)
elpd_hat = matrix(0, iter, 3)

set.seed(1)
for (i in 1:iter){
  # create 3 random predictors
  x1 = sample(c(-1,1), n, replace=TRUE)
  x2 = sample(c(-1,1), n, replace=TRUE)
  x3 = sample(c(-1,1), n, replace=TRUE)

  # generate the observed (in sample) data with an
  # underlying process that only uses the x1 predictor
  y = 1 + x1 + rnorm(n, 0, 1)
  # use the same process to simulate some "out-of-sample" data
  y_tilde = 1 + x1 + rnorm(n, 0, 1)

  for (j in 1:3){
    # fit three models, the first using the real underlying model
    if (j==1) mod = lm(y ~ 1+x1)
    # the next two include random useless predictors
    if (j==2) mod = lm(y ~ 1+x1 + x2)
    if (j==3) mod = lm(y ~ 1+x1 + x2 + x3)
```


```
    # find the predicted value (mu) for each data point
    mu = mod$fitted.values
    # and the estimated sigma parameter
    sigma = summary(mod)$sigma

    # equivalent to equation 6.10
    lpd_hat[i,j] = sum(dnorm(y, mu, sigma, log = TRUE))
    # equivalent to equation 6.11
    elpd_hat[i,j] = sum(dnorm(y_tilde, mu, sigma, log = TRUE))
  }
}
```

Simulating Prediction

$$\widehat{\text{lpd}} = \sum_{i=1}^N \log\left(\text{N}\left(y_{[i]} \mid \mu, \sigma\right)\right)$$

$$\widehat{\text{elpd}} = \sum_{i=1}^N \log\left(\text{N}\left(\tilde{y}_{[i]} \mid \mu, \sigma\right)\right)$$



Penalizing Prediction

- Los modelos más complejos siempre mejoran el lpd.
- Podemos estimar elpd penalizando lpd de acuerdo con la complejidad del modelo.
- Podemos llamar a la penalización p .


$$\widehat{\text{lpd}} = \sum_{i=1}^N \log\left(p(y_{[i]} | \theta)\right)$$

$$\text{elpd} = \sum_{i=1}^N \mathbb{E}\left(\log\left(p(\tilde{y}_{[i]} | \theta)\right)\right)$$

$$\rightarrow \widehat{\text{elpd}} = \widehat{\text{lpd}} - p$$

Simulating Prediction

$$\widehat{\text{lpd}} = \sum_{i=1}^N \log\left(\mathcal{N}(y_{[i]} | \mu, \sigma)\right) \quad \widehat{\text{elpd}} = \sum_{i=1}^N \log\left(\mathcal{N}(\tilde{y}_{[i]} | \mu, \sigma)\right) \quad \widehat{\text{elpd}} = \widehat{\text{lpd}} - p$$



Cross Validation

- Por lo general, no puede tener datos fuera de la muestra.
- Puede replicar datos fuera de la muestra de la siguiente manera:
 1. Retener algunos de sus datos al ajustar su modelo.
 2. Predecir los datos retenidos mediante el modelo.
- A esto se le llama validación cruzada.

Cross Validation

- Los datos que se utilizan para el modelo son los datos de entrenamiento. Los datos retenidos son los datos de prueba.
- Hay diferentes formas de realizar validaciones cruzadas:
 - Holdout: Haga una partición para pruebas y entrenamiento.
 - k-fold: Divide los datos en k partes. Cada una de las partes k tiene su turno siendo la prueba.
 - Dejar uno fuera: Para los datos con n puntos, cada punto tiene su turno como la prueba.

Leave-one-out (LOO)

- En realidad, no ajustaremos n modelos, podemos estimar la predicción fuera de la muestra usando LOO con el paquete `loo` en R.
- Esto nos dirá cuál es el "mejor" modelo teniendo en cuenta la complejidad del modelo.
- LOO es extremadamente robusto y puede comparar modelos que difieren en muchos aspectos.

Leave-one-out (LOO)

$$\widehat{\text{elpd}}_{LOO} \approx \sum_{i=1}^n \log \left(p \left(y_{[i]} \mid \theta_{y_{[-i]}} \right) \right)$$

$$\widehat{\text{elpd}}_{LOO} = \widehat{\text{lpd}} - \text{p}_{LOO}$$

$$\text{p}_{LOO} = \widehat{\text{lpd}} - \widehat{\text{elpd}}_{LOO}$$

Adding the LOO Criterion

```
model_sum_coding =  
  brms::add_criterion (model_sum_coding, criterion="loo")
```

```
model_sum_coding$criteria$loo  
##  
## Computed from 5000 by 1401 log-likelihood matrix  
##  
##           Estimate      SE  
## elpd_loo   -5042.7  32.5  
## p_loo       82.2   3.8  
## looic      10085.4  65.1  
## -----  
## Monte Carlo SE of elpd_loo is 0.2.  
##  
## All Pareto k estimates are good (k < 0.5).  
## See help('pareto-k-diagnostic') for details.
```

Estimación de
ELPD

Número efectivo
de parámetros

clon de AIC
(-2* ELPD)

Effective Number of Parameters

- En modelos muy simples, el término p está relacionado con el número de parámetros del modelo independiente.
- El número de parámetros "independientes" no es tan obvio para los modelos multinivel.
- La cantidad de flexibilidad puede considerarse como el "número efectivo de parámetros".

Effective Number of Parameters

```
# Actual and effective number of parameters
# for simplest model
ncol(bmmb::get_samples(model_sum_coding))-2
## [1] 114
sum(model_loo_info[, 'p_loo'])
## [1] 82.17

# for t model
ncol(bmmb::get_samples(model_sum_coding_t))-2
## [1] 115
sum(model_t_loo_info[, 'p_loo'])
## [1] 85.23

# for 'random effects' model
ncol(bmmb::get_samples(model_re_t))-2
## [1] 132
sum(model_re_t_loo_info[, 'p_loo'])
## [1] 109.1
```

Model Comparison

```
brms::loo_compare (model_sum_coding,  
                  model_sum_coding_t,  
                  model_re_t, criterion = "loo")  
##               elpd_diff se_diff  
## model_re_t           0.0       0.0  
## model_sum_coding_t -204.4      19.2  
## model_sum_coding   -224.1      19.6
```

```
brms::loo_compare (model_sum_coding, model_sum_coding_t,  
                  criterion = "loo")  
##               elpd_diff se_diff  
## model_sum_coding_t    0.0       0.0  
## model_sum_coding   -19.6       7.6
```

Adding a Useless Parameter

```
brms::fixef(model_re_t_tooBig)
##              Estimate Est.Error      Q2.5      Q97.5
## Intercept 155.4454      1.1583 153.1882 157.7513
## A1         8.5267       1.1226  6.2757 10.7094
## useless    0.3362       0.2522 -0.1688  0.8357
```

```
brms::loo_compare (model_re_t, model_re_t_tooBig)
##              elpd_diff se_diff
## model_re_t_tooBig  0.0      0.0
## model_re_t        -0.7      2.8
```

Traditionalist's Corner: lmer

```
# get data
notmen = bmmb::exp_data[exp_data$C_v!='m' & exp_data$C!='m',]

lmer_model = lme4::lmer (height ~ A + (A|L) + (1|S), data = notmen)

lmer_model
## Linear mixed model fit by REML ['lmerMod']
## Formula: height ~ A + (A | L) + (1 | S)
## Data: notmen
## REML criterion at convergence: 9890
## Random effects:
## Groups Name Std.Dev. Corr
## S (Intercept) 3.53
## L (Intercept) 4.12
## A1 3.98 -0.92
## Residual 7.67
## Number of obs: 1401, groups: S, 94; L, 15
## Fixed Effects:
## (Intercept) A1
## 155.05 8.64
```

Traditionalist's Corner: Imer

lme4

```
## Random effects:  
## Groups Name Std.Dev. Corr  
## S (Intercept) 3.53  
## L (Intercept) 4.12  
## A1 3.98 -0.92
```



brms

```
## Group-Level Effects:  
## ~L (Number of levels: 15)  
## Estimate Est.Error l-95% CI u-95% CI  
## sd(Intercept) 4.34 0.84 3.05 6.29  
## sd(A1) 4.26 0.85 2.96 6.25  
## cor(Intercept,A1) -0.80 0.12 -0.95 -0.51
```

